



Plan de Trabajo — Seminario Final

Licenciatura en Ciencia de Datos
Universidad Nacional Guillermo Brown

Título tentativo: Clasificación del origen natural o antrópico de incendios forestales en Estados Unidos a partir de variables de registro básicas (FPA-FOD, 1992–2015).

Estudiante: Facundo Tarizzo

1. Planteo del problema

Los incendios forestales constituyen un problema ambiental y de gestión pública. Su prevención requiere conocer por qué se originan, y esa información proviene de los registros que elaboran las agencias encargadas del manejo del fuego. Dentro de ese campo, el problema que aborda este trabajo es la atribución de la causa de ignición: determinar si un incendio se originó por un fenómeno natural, que en la base utilizada corresponde únicamente al rayo, o por actividad humana.

La relevancia de este problema se sostiene en tres argumentos. En primer lugar, las causas naturales y las humanas exigen respuestas distintas. Frente al rayo no existe una política de prevención posible, y la gestión se limita a la detección temprana y a la capacidad de respuesta. Frente a la ignición humana, en cambio, se puede intervenir. Las herramientas disponibles incluyen restricciones de acceso en temporada seca, control de quemas de residuos, mantenimiento de líneas eléctricas y campañas de concientización. La proporción de cada tipo de incendio en una región indica, por lo tanto, dónde tiene sentido invertir en prevención.

En segundo lugar, el dato de causa no siempre está disponible. La base FPA-FOD registra 1.880.465 incendios ocurridos en Estados Unidos entre 1992 y 2015, y 166.723 de ellos no tienen causa reportada, casi el 9 % del total. Una inspección preliminar sugiere que esos faltantes no se distribuyen al azar, sino que se concentran en determinados estados y períodos. Si esto se confirma, cualquier estadística agregada sobre la proporción de incendios naturales está sesgada por esa ausencia, y el sesgo afecta precisamente a las regiones donde la información es más necesaria.

En tercer lugar, los antecedentes que obtienen buenos resultados en esta tarea trabajan sobre versiones de la base enriquecidas con cientos de covariables ambientales y sociales que no forman parte del registro original. Construir ese enriquecimiento requiere fuentes externas y un procesamiento que no siempre está al alcance de los organismos que producen los registros. Además, el antecedente más directo evalúa sus modelos con una partición aleatoria, que en datos con estructura temporal y espacial tiende a sobreestimar el desempeño.

De estos tres argumentos se desprende la pregunta que orienta el trabajo: qué capacidad de atribución de causa puede obtenerse usando únicamente las variables que aporta el propio registro administrativo, cuando el modelo se evalúa en condiciones similares a las de su uso real.

2. Antecedentes

Short (2014) describe la construcción de la FPA-FOD (*Fire Program Analysis Fire-Occurrence Database*) para el Servicio Forestal de Estados Unidos. La autora reúne registros de agencias federales, estatales y locales, los lleva a un formato común y depura los duplicados que surgen cuando varias agencias informan el mismo incendio. Según su documentación, cada registro incluye ubicación, fecha, superficie quemada, jurisdicción y causa de ignición. Short (2014) advierte, además, que los registros estatales y locales no están disponibles para todos los estados en todos los años. Esa advertencia anticipa el problema de faltantes que propongo estudiar. La cuarta edición de la base, que utilizo en este trabajo, extiende la serie hasta 2015 (Short, 2017).

Pourmohamad et al. (2025) constituyen el antecedente más directo, ya que abordan la atribución de causa sobre esta misma base. Entre sus autores se encuentra la propia Short. Los autores trabajan con la sexta edición, que cubre el período 1992–2020, y restringen el análisis a once estados del oeste de Estados Unidos. Construyen una versión ampliada de la base con aproximadamente 270 covariables de clima, vegetación, topografía, población y manejo, de las cuales seleccionan 39. Con ellas entrenan siete modelos: cinco de *ensemble* y dos redes convolucionales. Los autores obtienen el mejor desempeño con XGBoost. Al clasificar entre doce causas, reportan una exactitud superior al 70 %. Al separar causas naturales de humanas, alcanzan el 93 %. Entre las once causas humanas, en cambio, la exactitud desciende al 55 %. Ese contraste sostiene mi decisión de plantear el problema en términos binarios. Pourmohamad et al. (2025) aportan además un dato que se vincula con la advertencia de Short (2014): las agencias federales dejan sin causa el 13 % de sus registros, mientras que las no federales lo hacen en el 48 %. Según este resultado, el faltante depende en parte de quién informa.

Dos decisiones de Pourmohamad et al. (2025) limitan la comparación directa con este trabajo. La primera es el recorte regional. La segunda es la partición aleatoria de los datos. Roberts et al. (2017) permiten valorar esta última. Los autores muestran que, cuando las observaciones presentan autocorrelación temporal o espacial, una partición aleatoria deja en el conjunto de prueba casos muy similares a los de entrenamiento. El resultado es una estimación optimista del desempeño real. Como alternativa, proponen dividir los datos en bloques que respeten esa estructura y que reproduzcan el uso previsto del modelo. Ese criterio fundamenta el esquema de validación temporal que adopto.

Coffield et al. (2019) abordan una tarea distinta sobre incendios de los bosques boreales de Alaska: predecir, al momento de la ignición, si un incendio alcanzará un tamaño final pequeño, mediano o grande. Con un árbol de decisión y solo dos variables, el déficit de presión de vapor y la fracción de cobertura de abeto, obtienen una exactitud del 50,4 %. Algoritmos más complejos, como Random Forest y el perceptrón multicapa, no superan a ese modelo simple. El trabajo resulta pertinente por dos motivos. Muestra el orden de dificultad de las predicciones basadas en la información disponible al inicio de un incendio. Y respalda la necesidad de comparar siempre los modelos complejos contra una referencia simple antes de justificar su uso.

En cuanto a los algoritmos, Breiman (2001) define Random Forest como un conjunto de árboles de decisión entrenados sobre muestras de los datos y subconjuntos aleatorios de variables. Prokhorenkova et al. (2018) presentan CatBoost, un algoritmo de *boosting* que incorpora un tratamiento nativo de variables categóricas mediante estadísticos de objetivo ordenados. Ese mecanismo evita la filtración de información que produce la codificación por objetivo aplicada de forma directa. Resulta especialmente adecuado para esta base, donde el estado y la agencia informante tienen muchas categorías. Para la interpretación de los modelos, Lundberg y Lee (2017) proponen los valores SHAP, que asignan a cada variable su contribución a una predicción particular. Pourmohamad et al. (2025) emplean este mismo método, lo que permite contrastar qué variables resultan relevantes en ambos trabajos.

Dentro de la bibliografía relevada no identifiqué trabajos que evalúen la atribución de causa

sobre la totalidad del territorio de Estados Unidos, con variables del registro administrativo únicamente y bajo un esquema de validación temporal.

3. Objetivos

3.1. Objetivo general

Desarrollar y evaluar un modelo de clasificación que estime la probabilidad de que un incendio registrado en la base FPA-FOD sea de origen natural, a partir de las variables del registro administrativo, para permitir la atribución de causa en registros incompletos.

3.2. Objetivos específicos

1. Caracterizar la distribución de las causas de ignición según su frecuencia, su estacionalidad y su ubicación geográfica.
2. Establecer si los registros sin causa reportada responden a un patrón y qué factores lo explican.
3. Diseñar un esquema de validación temporal que evite la sobreestimación del desempeño.
4. Comparar el desempeño de un modelo lineal de referencia con el de dos algoritmos de *ensemble*.
5. Identificar las variables que explican la predicción y la dirección de su efecto.
6. Contrastar los resultados obtenidos con los reportados en la literatura para la misma tarea.

4. Actividades y metodología

Preparación de los datos. Cargaré la base desde su formato original SQLite y reduciré las 39 columnas disponibles a las pertinentes para el análisis. Descartaré los identificadores, las columnas con una proporción elevada de valores faltantes y los códigos numéricos que duplican información ya presente en formato de texto.

Análisis exploratorio. Describiré la distribución de causas, su estacionalidad a partir del día del año de descubrimiento, su distribución geográfica y la evolución del registro a lo largo del período. Para estudiar los faltantes construiré una matriz de estado por año y la contrastaré con el volumen de registros de cada celda. Esto permitirá distinguir un período sin incendios registrados de un período con incendios mal documentados. Examinaré, además, la relación entre los faltantes y el tipo de agencia informante.

Definición de la variable objetivo. Construiré una variable binaria que distinga la causa natural, que en esta base corresponde únicamente al rayo, de la causa antrópica, que agrupa las once categorías restantes. Los registros sin causa reportada quedarán excluidos del modelado, ya que no cuentan con una etiqueta verificable.

Esquema de validación. Aplicaré una validación temporal progresiva en cuatro lotes sucesivos. Cada lote se entrenará con los años precedentes y se evaluará sobre el bloque inmediatamente posterior. Esta decisión se apoya en Roberts et al. (2017) y busca reproducir la situación de uso real del modelo. El esquema aportará, además, cuatro mediciones en lugar de una, lo que permitirá reportar una media y una dispersión. Dentro del período de entrenamiento de cada lote reservaré los últimos años como conjunto de validación. Ese conjunto se usará exclusivamente para fijar el umbral de decisión y los criterios de detención del entrenamiento. De este modo, el conjunto de prueba no intervendrá en ninguna decisión previa a la evaluación final.

Modelado. Utilizaré la regresión logística como modelo de referencia, con estandarización

de las variables numéricas y codificación *one-hot* de las categóricas. Sobre esa base evaluaré Random Forest y CatBoost. Random Forest se entrenará sobre una submuestra del conjunto de entrenamiento, dado que su implementación en `scikit-learn` no aprovecha la GPU. En el caso de CatBoost, el tratamiento nativo de variables categóricas resulta especialmente adecuado, porque dos de las variables previstas presentan cardinalidad elevada.

Evaluación. Dado el desbalance esperado entre clases, priorizaré el área bajo la curva de precisión-sensibilidad por sobre la exactitud. Incorporaré también el área bajo la curva ROC, la exactitud balanceada y el coeficiente de correlación de Matthews. El umbral de decisión se seleccionará maximizando F1 sobre el conjunto de validación. Reportaré, además, el comportamiento del modelo en umbrales alternativos, para explicitar el compromiso entre precisión y sensibilidad.

Interpretación y análisis de errores. Calcularé la importancia de las variables y los valores SHAP, para establecer no solo qué variables pesan sino en qué dirección actúan. Caracterizaré los errores según la ubicación, el momento del año y la magnitud del incendio.

Todo el desarrollo se implementará en Python, con `pandas` para el manejo de datos, `scikit-learn` para los modelos de referencia y las métricas, `catboost`, `shap` para la interpretabilidad, y `matplotlib` junto con `seaborn` para las visualizaciones.

5. Factibilidad

Disponibilidad de los datos. La base FPA-FOD es de acceso público y ya la tengo descargada. Se distribuye en Kaggle bajo el nombre *1.88 Million US Wildfires*, y su versión original está publicada en el Forest Service Research Data Archive con DOI asignado. Ocupa aproximadamente 795 MB en formato SQLite y no requiere permisos ni convenios de acceso.

Acceso a software. El trabajo se desarrolla íntegramente con herramientas de código abierto sobre Google Colab, que provee acceso a una GPU Tesla T4. Ya verifiqué que el volumen de datos y los algoritmos previstos son manejables en ese entorno.

Acceso a la bibliografía. Las referencias centrales son de acceso abierto. El artículo de Pourmohamad et al. (2025) está publicado en *Earth's Future*, una revista de acceso abierto, al igual que Short (2014) en *Earth System Science Data* y Coffield et al. (2019) en el *International Journal of Wildland Fire*. Los trabajos de Prokhorenkova et al. (2018) y de Lundberg y Lee (2017) están disponibles en arXiv. Cuento con acceso a las referencias restantes.

Tiempo de trabajo. Estimo el desarrollo en 10 semanas. Las tres primeras estarán destinadas a la preparación de los datos y al análisis exploratorio. Las cuatro siguientes, al desarrollo y la evaluación de los modelos. Las tres últimas, a la redacción del informe final. La fecha prevista de entrega es el 26 de noviembre de 2026. Cuento con la disponibilidad horaria necesaria para cumplir ese cronograma.

6. Material adicional

El desarrollo se documenta en un repositorio público de GitHub que contiene el código completo, organizado en dos cuadernos de Jupyter ejecutables sobre Google Colab. El primero cubre la limpieza de datos y el análisis exploratorio, con las figuras correspondientes y su interpretación. El segundo contiene el esquema de validación, la comparación de modelos, las métricas, el análisis de interpretabilidad y el análisis de errores.

El repositorio incluye además una carpeta con las figuras exportadas en alta resolución, un archivo de dependencias que permite reproducir el entorno de ejecución y este plan de trabajo. El README documenta la pregunta de investigación, el esquema metodológico, los resultados obtenidos y las limitaciones identificadas.

7. Referencias

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://link.springer.com/article/10.1023/A:1010933404324>
- Coffield, S. R., Graff, C. A., Chen, Y., Smyth, P., Foufoula-Georgiou, E., & Randerson, J. T. (2019). Machine learning to predict final fire size at the time of ignition. *International Journal of Wildland Fire*, 28(11), 861–873. <https://connectsci.au/wf/article/28/11/861/21485/Machine-learning-to-predict-final-fire-size-at-the>
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774. <https://arxiv.org/abs/1705.07874>
- Pourmohamad, Y., Abatzoglou, J. T., Fleishman, E., Short, K. C., Shuman, J., AghaKouchak, A., Williamson, M., Seydi, S. T., & Sadegh, M. (2025). Inference of wildfire causes from their physical, biological, social and management attributes. *Earth's Future*, 13(1), e2024EF005187. <https://agupubs.onlinelibrary.wiley.com/doi/10.1029/2024EF005187>
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31, 6638–6648. <https://arxiv.org/abs/1706.09516>
- Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., & Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8), 913–929. <https://nsojournals.onlinelibrary.wiley.com/doi/10.1111/ecog.02881>
- Short, K. C. (2014). A spatial database of wildfires in the United States, 1992–2011. *Earth System Science Data*, 6(1), 1–27. <https://essd.copernicus.org/articles/6/1/2014/>
- Short, K. C. (2017). *Spatial wildfire occurrence data for the United States, 1992–2015 [FPA_FOD-20170508]* (4.^a ed.) [Conjunto de datos]. Forest Service Research Data Archive. <https://doi.org/10.2737/RDS-2013-0009.4>